

VOLUME AI

问玄东方

AI 智能体使用与验收

多步执行 · 补充资料 · 报告追问 · 运营管理

说明 AI 问事 Harness 的操作方式、现有能力、管理员配置和可重复执行的验收步骤。
区分产品能力、生产发布、真实验证与尚未交付的端差异。

2026-09-29 · 用户 / 产品 / 运营 / 测试

0.0.1 / 产品手册系列

当前实现、操作说明与证据边界

阅读导航

目录页码可点击跳转；PDF 书签按章节组织。正文中的金色链接指向官方来源或核对资料。

1. 从哪里进入	3
2. 普通用户怎么用	3
3. 能力清单	4
4. 管理员怎么配置	6
5. 怎么测试	7

阅读说明

更新：2026-09-29。适用本次 Harness 版本的 H5、AI 服务与总管理台。部署版本和真实验收结果见全工具接入记录、上下文升级记录和首版发布记录。本说明不包含账号口令、个人报告或模型密钥。

1. 从哪里进入

- 信众：登录后进入底部“AI问事”，选择“问事”直接输入问题，或在“发现 → 问事技能”选择具体能力。
- 报告追问：进入“我的报告”，打开已解锁报告，选择“围绕这份报告继续问事”。
- 总管理员：总管理台“AI 问事 → 智能体运营管理”，地址 </admin/ai/operations>。模型连接由原“AI 模型设置”维护。

用户名/邮箱、密码和图片验证码沿用现有登录方式。本次没有重置管理员密码。智能体运营配置要求平台超级管理员，寺院或大师账号不能代替。

2. 普通用户怎么用

直接提问

先说明想解决的事情，例如“我在换工作和留下之间犹豫，帮我梳理判断标准”。这类问题可直接讨论，不强制排盘。需要实际计算时，智能体会选择当前启用的工具，读取结果后回答。

页面显示准备、判断下一步、读取报告、调用工具或生成回答等阶段。处理过程可能包含多个模型和工具步骤；没有逐字输出时也可能正在执行任务。不要反复发送相同问题。

缺少资料时

1. 从具体计算技能新建会话时，缺资料会直接显示“补充资料并继续”；普通问事由智能体按需补问。
2. 打开表单，检查已填内容，补充确知的日期、时间、历法或其他必要信息。
3. 点击“确认资料并继续”，本次资料随原会话保存，智能体围绕原问题继续执行。
4. 不知道必填信息时，不要猜测；可关闭表单，改为讨论一般性问题。关闭不会伪造计算结果，也不会清空已有会话。

已确认资料来自用户表单和关联报告原始资料，不从助手输出反推事实。资料只用于当前会话，尚无跨会话长期档案。刷新后从历史问事继续即可。

围绕报告继续问

先解锁报告，再由报告入口进入关联会话。例如“解释这份报告中已有的十神信息，哪些结论有工具依据？”智能体可以读取该会话关联的报告，并按需要追加已有工具支持的计算。

报告正文与原始资料分别处理。不会把报告中的推测当成新的出生资料，也不能通过输入其他报告编号读取别人的报告。每轮会重新核对报告归属与解锁状态。

八字命盘与大运是两个独立工具。询问大运、流年时，Harness 可继续调用 `bazi_dayun`，读取完整的大运、流年及太岁关系后回答；紫微运限和飞星也分别使用自己的工具。出生地点校正仍取决于 MCP 返回的地点解析状态，不能把“已填写地点”当作“已完成真太阳时校正”。

查看依据与处理失败

回答下方的“查看处理过程”展示实际工具调用及成功/失败状态；没有工具调用时会明确说明。它不展示模型隐藏思考链，也不等于专业结论认证。成功回答还展示上下文估算占用、有效窗口和输出预算；供应商返回的实际输入/输出 Token 另行展示，不能把估算值当成账单。

生成期间可以点击“停止生成”，停止后该消息保留并可重试。关闭网页不等于停止服务端任务；连接中断时页面会继续查询任务状态。

失败时使用原消息的“重试”，问题和报告仍在原会话。工具暂不可用时，智能体可在预算内再次尝试；没有结果就应说明限制。服务正在外部调用时若重启，不会假装已完成，也不自动无限重放请求。

3. 能力清单

能力	当前行为	边界
多步执行	模型根据观察结果选择下一步，工具结果返回后可继续调用	每轮最多 4 次模型调用、4 次工具调用；默认任务时限 180 秒
一般问答	解释、梳理、文化交流，可直接回答	不必为了显得复杂而调用工具
关联报告	读取当前用户当前会话的已解锁报告	不支持任意报告编号、外部文档库检索
计算工具	15 个 taibu 计算工具全部适配；另有日常问事、姻缘、风水 3 项综合技能	MCP 和具体技能必须可用；不等于工具支持全部推算项目
资料补问	结构化表单、条件必填、复用已确认资料	模型不能自行填入出生时间等事实
历史与继续	消息及资料持久化，刷新后可继续	用户下一轮重建上下文；不是外部模型请求断点续传
图片问事	延续已存在的最多三张图片与视觉模型支持	必须选择支持图片的模型
失败恢复	有限工具重试；思考耗尽且无答案时可进行一次兼容降级重试	不提高原 Token/次数上限，不把截断答案当完成
可观察性	阶段、工具记录、模型/工具次数、用量与配置单价费用	上游未提供 usage 时无法推算精确用量
运营管理	技能策略、版本快照、评测、分批放量、回滚与审计	保存草稿不等于对用户生效

15 个计算工具怎么选

“发现 → 问事技能”按三类展示。点击技能后进入新问事，先编辑你的问题再发送。助手需要资料时会显示补问表单；不会仅凭一句自然语言就自行猜测出生参数。

技能 / MCP 工具	用途	必要资料或选项
八字命盘 <code>bazi</code>	四柱、十神、命盘关系	历法、出生日期时间、性别；地点选填
八字大运 <code>bazi_dayun</code>	起运、大运、小运、流年与太岁关系	历法、出生日期时间、性别
四柱反推 <code>bazi_pillars_resolve</code>	查询可能的出生时间	年、月、日、时四个有效干支；返回候选需本人确认
紫微命盘 <code>ziwei</code>	十二宫与星曜	历法、出生日期时间、性别
紫微运限 <code>ziwei_horoscope</code>	大限、小限及指定日期运限	出生资料、目标日期；流时时段可选
紫微飞星 <code>ziwei_flying_star</code>	四化落宫、自化、三方四正、宫位飞入	出生资料、查询宫位及方式；飞入需目标宫位
西方占星 <code>astrology</code>	本命盘及指定时刻流运	出生地当地公历日期时间、经纬度、流运北京时间
奇门遁甲 <code>qimen</code>	九宫、九星、八门与八神	北京时间起局时刻
塔罗 <code>tarot</code>	9 种牌阵抽牌	牌阵、具体问题；包括单牌、三牌、爱情、抉择等
六爻 <code>liuyao</code>	六爻排盘与用神	关注事项；自动、时间、数字或指定卦
梅花易数 <code>meihua</code>	卦象与体用关系	起卦时刻；时间、两数、三数、字占、物声数、尺寸、类象或指定卦
太乙九星 <code>taiyi</code>	不同尺度的时空底盘	时刻，以及年、月、日、时、分尺度
大六壬 <code>daliuren</code>	天地盘、四课、三传与神将	北京时间起课时刻
小六壬 <code>xiaoliuren</code>	农历月日时辰起课	农历月日、明确时辰；子时为第一时辰
黄历 <code>almanac</code>	日期宜忌与时辰参考	公历日期；已知日主可选填

日常问事、姻缘、风水属于综合对话技能，没有额外独立的计算引擎；按问题需要可使用已确认资料调用上述工具。梅花与六爻已拆开，不再把同一工具包装为两种计算。技能是平台审核的规则、输入契约与工具绑定；不是任意上传脚本或自动安装外部插件。

公历与农历不能混填；农历闰月尚无专门表单，需自行确认对应公历日期。西方占星的出生时间按出生地当地时间，流运时刻按表单标明的北京时间。经纬度必须由用户确认，系统不会偷偷使用默认城市。四柱反推只给候选，不自动写入原始出生资料。

当前没有任意联网搜索、RAG 知识库、跨会话长期记忆、多智能体协作、可视化流程编排、智能体付款或代下单。专题报告首次生成仍沿用原报告流程，报告后的多轮追问走 Harness。

原生 iOS 仍使用现有 API 和界面。本次新增的补充资料弹窗、处理记录展示首先交付 H5；不能宣传 iOS 已完成同样的交互验收。

4. 管理员怎么配置

模型连接

在 AI 模型设置中核对服务地址、密钥、默认模型、可用模型与输出额度。Harness 当前要求兼容 OpenAI 接口且支持工具调用的模型。普通连接测试只证明连接可用，应继续执行工具用例验证。

修改模型设置后，新请求使用新快照，正在执行的请求保留原快照。不要将 API Key 放入提示词、评测资料或文档。

上下文与生成额度

总管理平台“AI 模型设置”可调整以下额度；修改后点击“保存并生效”，系统再次验证模型连接，新请求使用新配置。

设置	本次生产生效值	管理平台范围与说明
普通问事输出	8,192 Token	64-32,768；每次模型调用的上限，可能包含思考 Token
复杂分析输出	16,384 Token	不低于普通额度，最高 32,768；关联报告、结构化计算资料或明确要求详细分析时使用
平台上下文	1,048,576 Token (1M)	32,768-1,048,576；输入、历史、工具、输出及安全预留共同占用
单次输入	20,000 字符	2,000-100,000；字符数与 Token 数不是同一单位
异步任务时限	180 秒	60-600；每轮整体预算，并非每个模型调用重新计时

实际上下文取平台配置和所选模型声明容量的较小值；模型未提供容量时按 32K 保守处理。输出还受模型最大输出及可用窗口限制。供应商声明 1M 上下文不代表平台会生成 1M 输出，也不代表每次调用都发送满 1M 内容。

Harness 不再按固定最近 30 条、40KB 截断历史。每次模型调用前按预算组装上下文，优先保留系统要求、用户确认资料、当前问题以及当前工具调用与结果。必要时移除完整的旧轮次，余量允许时附上旧用户问题摘录。

这是有限历史压缩，不是大模型摘要或跨会话长期记忆；当前轮次本身过大时会明确失败，不悄悄丢弃工具结果。

当前估算使用 UTF-8 字节保守计数，并为图片、工具定义和协议留量，不是 DeepSeek 精确分词器。实际计费用量以供应商 usage 为准。平台输出范围有意收敛到 32K；不能把供应商可能更高的最大输出量直接等同于默认预算。

发布的智能体版本可进一步收紧输出预算；需要放宽时，应修改草稿、重新评测并发布。后台单次快速调试仍有独立的 512 Token / 50 秒限制，整组评测也有总体时限，不等同于用户异步任务额度。专题报告首次生成使用复杂输出额度，报告追问使用 Harness。

智能体运营工作区

- 1. 查看工作区顶部实际运行模式。显示 Harness 才表示用户问事采用多步执行器。
- 2. “技能与工具”列出完整目录。已有草稿缺少新技能时，点击“将新技能加入草稿”，再检查提示词和开关；不会自动改动已发布版本。调整名称、全局要求、默认模型、输出额度、技能启停及提示词；工具地址沿用后端白名单，不能从页面任意添加执行程序。
- 3. 保存草稿。保存使用修订号校验，发生冲突时重新读取，不覆盖其他人的修改。
- 4. 使用合成资料调试。后台保留旧流程作为对照，单次调试成功不是发布凭证。
- 5. 为每个启用技能至少配置一条正常回答评测，再加入类型错误、禁止输出等用例。真实个人资料不要写进明文评测配置。
- 6. 运行整组评测，查看输出长度、必含/禁含内容、工具调用和失败原因。缺少资料引发补问，不能算“非法资料已拒绝”的通过用例。
- 7. 只有当前草稿、模型连接和执行引擎匹配，且 24 小时内评测通过，才能发布候选版本。

放量与回滚

有两个独立服务开关：`AI_HARNESS_ENABLED` 控制执行引擎；`AI_AGENT_OPERATIONS_ENABLED` 控制已发布配置是否接管用户请求。只启用前者时，用户已经使用 Harness，但沿用已有技能目录和配置。

管理台候选版本从 0% 开始，按账号稳定分桶；先完成测试，再按 10%、25%、50%、100% 逐步扩大。未命中的账号使用稳定版本或原始配置。每次修改比例填写说明。

旧普通问答引擎的评测不能用于 Harness 发布或激活。切换引擎、修改模型配置后需要重新评测。出现问题时可回滚历史配置或恢复原始配置；需要切回旧执行器时由运维关闭 Harness 开关并重建服务。

5. 怎么测试

以下是可重复执行的测试清单，不表示每条已在生产完成。执行证据和未验收项见发布记录。

场景	操作	应观察到的结果
一般问题	新会话输入生活讨论问题	正常回答，可无工具调用

场景	操作	应观察到的结果
资料不足	请求排盘但不提交结构化资料	补问表单出现，不编造计算结果
补充继续	填入合成日期与时间并确认	保留原问题，执行工具后回答
报告追问	从自己已解锁报告继续问事	读取关联报告；无权报告不能读取
全工具覆盖	对 15 项工具使用合成资料测试	工具成功、有依据返回、处理过程名称正确
子选项	塔罗 9、梅花 8、六爻 4、飞星 4、太乙 5 种选项分别测试	仅展示对应资料，传参符合 MCP 契约
数字校验	占星纬度填 91、小六壬农历日填 31	资料拒绝，不继续计算
条件必填	六爻选择数字方式但不填数字	要求补充数字；改其他方式仅收集对应字段
失败重试	隔离环境模拟工具失败	有限重试或明确失败，不伪装成功
长输入	独立测试会话提交超过 2,000、少于 20,000 字符的合成资料	接收成功；上下文信息展示实际模型窗口
停止生成	生成期间点击停止，再按需重试	当前任务停止，消息保留；不能停止其他用户任务
历史压缩	隔离环境使用小窗口与长历史	旧轮次按预算裁剪，当前问题与工具配对保留
预算限制	隔离环境持续要求调用工具	达到上限结束，不无限调用
重启继续	在等待补资料时刷新页面	能找回会话并继续提交
移动输入	手机 Safari 打开补问表单	输入字体与弹窗可用，提交值完整；真机需独立验证
发布门槛	修改草稿或模型后直接发布	必须重新评测，不能复用过期或旧引擎通过记录
权限	非超管访问智能体运营接口	拒绝访问，不提升角色权限

这些测试涉及模型调用额度，但不需要真实支付或制造真实订单。生产测试应使用独立测试账号与合成资料，避免重放个人报告。